

경쟁자가 아닌 feature 엔진으로서의 SSL: 표 형식 신용 부도 예측을 위한 자기지도 사전학습

Anonymous*

2026년 5월

요약

문제. 신용 부도 예측은 실무에서 거의 항상 도메인 지식이 응축된 hand-crafted aggregated feature 위의 gradient boosting machine (GBM)에 의존한다. 자연어 처리와 컴퓨터 비전에서 자기지도 사전학습 (self-supervised learning, SSL)이 가져온 성공을 신용 영역에 옮기려는 시도가 여러 차례 있었으나, “SSL이 GBM을 이긴다/진다”라는 결론이 발표마다 일관되지 않으며, 어떤 조건에서 어느 방향이 맞는지 분해된 분석이 부족하다.

방법. 본 연구는 AMEX Default Prediction (Kaggle 2022; 458,913 고객 × 최대 13개월의 anonymized 거래 시퀀스) 데이터를 사용해 통제 실험으로 그 모호함을 분해한다. 동일한 customer-level 80/10/10 split, 동일한 AMEX 메트릭, 동일한 transformer encoder backbone으로 네 가지 SSL objective(masked feature modeling, next-step prediction, contrastive, hybrid)를 학습한 뒤, 평가 프로토콜(linear probe vs full fine-tune), 라벨 양(1%–100%), feature 융합(SSL embedding을 GBM의 추가 입력으로 합치는 방식)의 세 축으로 비교한다. 모든 실험은 단일 8 GB GPU에서 수행되었다.

결과. 네 가지 발견을 보고한다. (1) 어떤 SSL 단독 모델도 잘 튜닝된 LightGBM baseline (test AMEX 0.7956)을 능가하지 못한다. (2) 동일한 인코더에 대해 linear probe와 full fine-tune의 결과가 0.058만큼 차이 나며, 기존 tabular SSL 문헌이 평가 프로토콜에 따라 정반대 결론을 내릴 수 있음을 보인다. (3) SSL embedding을 GBM의 보조 feature로 합치면 평균 test AMEX 0.79700 ± 0.0006 (3 seeds, $t = 4.1$)으로 baseline을 통계적으로 의미 있게 $+0.00142$ 상회한다. (4) 이 lift는 균등하지 않고, GBM이 “안전하다”고 자신한 prediction decile 0–3 영역에 $+0.02 \sim +0.03$ 집중되어 silent default 위험을 잡아낸다. 또한 ablation 분석은 SSL embedding이 hand-crafted top-100 feature 신호의 55%를 unlabeled raw 시퀀스로부터 자동 재발견함을 보이며, multi-encoder stacking은 음의 scaling을 나타내 NLP/Vision SSL 직감이 tabular credit에 그대로 이전되지 않음을 보인다.

시사점. SSL을 GBM의 경쟁자가 아닌 보조 feature 엔진으로 다루는 것이 — 그리고 그 가치가 false-negative tail에 집중된다는 것이 — 신용 risk 도메인에서 SSL을 도입할 합리적이고 측정 가능한 framing임을 정량적으로 보인다.

키워드: 자기지도 학습, 신용 risk, gradient boosting, 표 형식 데이터, 평가 프로토콜

*소속 / 이메일 (camera-ready 시 기입)

1 서론

1.1 신용 부도 예측의 산업 표준과 그 한계

소비자 신용 부도 예측은 가장 오래 연구된 응용 통계 문제 중 하나이며, 지난 10여 년간 산업 표준은 명확하다. 그것은 **수작업 집계 feature 위의 gradient boosting machine (GBM)**이다. 1억 건 이상 거래 시퀀스를 고객 단위 한 행으로 압축하기 위해, 실무자는 “마지막 값”, “지난 12개월 평균/분산”, “사용률의 추세”, “결측 패턴” 등 도메인 지식이 응축된 수백~수천 개의 집계 feature를 만들어 LightGBM 또는 XGBoost에 투입한다. Kaggle AMEX 2022 대회 상위 솔루션은 거의 모두 이 패턴이며, 본 연구의 자체 baseline 역시 1,291개의 hand-crafted feature로 학습한 LightGBM이 5-fold CV OOF에서 AMEX metric 0.79222, 5개 fold model을 bagging한 test에서 0.79558을 기록해 공개 leaderboard top-10 수준에 도달했다.

이 baseline은 두 가지 사실을 동시에 의미한다. 첫째, **수십 년의 expert engineering 지식이 데이터 파이프라인 자체에 사실상 사전학습되어** 있어, 새 모델이 그 위에서 의미 있는 lift를 얻기 어렵다. 둘째, 시퀀스 자체에 담긴 일시적 패턴은 집계 함수들로 손실 압축된다 — 어떤 정보가 그 압축 과정에서 사라지는지 정량적으로 알려진 바가 거의 없다.

1.2 NLP/Vision의 SSL 성공과 신용에서의 모호함

NLP와 컴퓨터 비전에서 SSL의 영향력은 더 이상 논쟁의 여지가 없다. masked language modeling, next-token prediction, contrastive learning, masked autoencoding은 모두 하나의 동일한 패턴을 따른다 — raw 신호 위에서 라벨 없이 사전학습된 표현이, 충분한 데이터와 컴퓨터가 있을 때 downstream에서 hand-crafted feature를 압도한다는 패턴이다. 이 성공이 신용 risk 도메인으로 옮겨질 수 있다는 직관은 자연스럽다. Sberbank의 E.T.-RNN, IBM의 TabBERT/TabGPT, 그리고 여러 후속 연구들은 거래 시퀀스에서 사전학습된 sequence encoder가 GBM 표준을 능가할 수 있다고 주장해 왔다.

문제는 결과의 일관성이다. 같은 종류의 모델, 비슷한 데이터 규모에서도 SSL이 GBM을 이긴다고 보고하는 논문과 진다고 보고하는 논문이 공존하며, 그 갈라지는 이유는 명확히 분해되어 있지 않다. 우리가 직접 네 가지 SSL objective를 동일한 인코더 backbone과 동일한 customer-level split 위에서 평가했을 때도, **평가 프로토콜 하나를 바꾸는 것만으로 AMEX metric이 0.058 단위로 움직였다**. 이 차이는 “SSL이 GBM에게 진다”와 “거의 비긴다”를 분리하는 결정적 폭이다.

본 연구의 출발점은 따라서 단순하다 — “SSL은 신용에 통하는가”는 잘못된 질문이며, 진짜 질문은 “어떤 평가 프로토콜에서, 얼마나 많은 라벨에 대해, 어떤 feature 융합 방식에서 SSL이 의미 있는 lift를 주는가”이다. 우리는 이 세 축을 통제된 실험으로 분해한다.

1.3 우리의 접근

본 연구는 단일 데이터셋(AMEX Default Prediction 2022, 458,913 고객 $\times$ 최대 13개월의 anonymized 거래 시퀀스)과 단일 GPU(RTX 4070 Laptop, 8 GB VRAM)라는 **단일 실험 환경**을 유지한 채, 다음 세 축을 통제 변수로 비교한다:

- **평가 프로토콜.** 동일한 SSL 인코더에 대해 (a) *linear probe* — 인코더를 freeze하고 mean-pool 위에 로지스틱 회귀를 학습 — 와 (b) *full fine-tune* — 인코더와 classification head를 함께 학습 — 두 가지 결과를 모두 보고한다.
- **라벨 양.** 동일한 stratified subset 추출 알고리즘으로 train+val 라벨의 1%, 5%, 25%, 100%를 사용한 GBM과 SSL fine-tune의 label-efficiency curve를 그린다.
- **Feature 융합.** SSL 인코더의 mean-pooled 128-차원 embedding을 GBM의 추가 입력 feature로 합쳤을 때의 marginal lift를 측정하고, ablation 및 segment 분해로 그 lift가 무엇을 보완하며 어디에 사는지 정량화한다.

네 가지 SSL objective(masked feature modeling, next-step prediction, SimCLR-style contrastive, hybrid)는 **동일한 4-layer transformer encoder backbone ($d = 128$, 869K parameters)**을 공유한다. 데이터 split은 data/splits/v1.parquet에 SHA-256 결정론적으로 고정되어 모든 실험이 동일한 train/val/test customer 집합을 사용한다.

1.4 기여

본 연구의 기여는 다음 네 가지이며, 모두 정량적으로 뒷받침된다:

1. **(직접 경쟁)** 어떤 SSL 단독 모델도 잘 튜닝된 LightGBM (test AMEX 0.7956)을 능가하지 못한다. 최고 SSL 단독 결과는 Hybrid + full fine-tune의 0.7927로, baseline에 -0.003 뒤진다. 또한 라벨 양을 1%~100%로 변화시킨 few-shot 비교에서 **GBM이 모든 fraction에서 우세하며**, 라벨이 줄어들수록 차이가 커진다(1% labels에서 $+0.052$). 이는 일부 SSL 문헌의 “low-label regime”에서 SSL이 강하다는 주장과 반대 방향이다.
2. **(평가 프로토콜)** Linear probe와 full fine-tune의 결과가 0.058만큼 차이난다. 이는 기존 tabular SSL 평가가 critically underspecified임을 시사한다. 같은 인코더로 보고하는 두 숫자가 -0.058 과 -0.003 사이를 오갈 수 있다면, “SSL이 약하다/강하다”는 어느 쪽 주장이든 protocol-conditional이다.
3. **(Feature 융합)** SSL embedding을 GBM의 추가 feature로 합치면 baseline을 통계적으로 의미 있게 상회한다. 3개의 SSL pretrain seed에서 측정한 평균 test AMEX는 0.79700 ± 0.0006 으로, baseline 대비 $+0.00142$ ($t = 4.1$, $df = 2$, 3/3 trial 이 양의 방향)의 lift를 준다. Best single seed에서는 $+0.00210$ 에 도달한다.

4. **(국소 효과)** Lift는 균등하지 않고, GBM이 “안전하다” 고 자신한 prediction decile 0–3 영역에 집중되어 silent default 위험을 잡아낸다. Per-decile AMEX 변화는 $+0.02 \sim +0.03$ 수준이며, 이는 credit-risk 실무에서 가장 비싼 false-negative failure mode에 정확히 해당한다. 또한 ablation 분석은 SSL embedding이 hand-crafted top-100 feature 신호의 **약 55%를 unlabeled raw 시퀀스로부터 자동 재발견**함을 보이며, multi-encoder stacking은 음의 scaling을 나타내 NLP/Vision SSL 직감이 tabular credit에 그대로 이전되지 않음을 보인다.

이 네 가지 발견은 종합적으로 **SSL을 GBM의 경쟁자가 아닌 보조 feature 엔진으로** 재배치하는 것이 신용 risk에서 SSL을 도입할 합리적이고 측정 가능한 framing임을 시사한다.

2 관련 연구

2.1 신용 risk에서의 sequence modeling 및 SSL

신용 데이터에 시퀀스 모델을 적용한 작업은 크게 두 갈래로 나뉜다. 첫째, RNN/LSTM 기반의 supervised end-to-end 학습이다. Sberbank의 E.T.-RNN은 거래 시퀀스에서 직접 부도 확률을 예측하는 LSTM 기반 architecture를 제안했고, 산업 데이터에서 logistic regression baseline을 능가함을 보고했다. 다만 이 비교에서 baseline이 hand-crafted feature 위의 GBM이 아닌 logistic regression이라는 점이 핵심 한계다 — GBM과의 직접 비교에서는 시퀀스 모델이 일관되게 이긴다는 증거가 없다.

둘째, 본 연구가 더 직접적으로 비교 대상으로 삼는 **사전학습 기반 접근**이다. Padhi et al.의 TabBERT와 TabGPT는 transaction 시퀀스 위에 BERT-style masked feature modeling 및 GPT-style next-step prediction을 적용했다. 이들은 fraud detection 및 default prediction에서 SSL 사전학습된 표현이 hand-crafted feature를 능가하는 조건을 일부 보고했지만, **평가는 linear probe 또는 fine-tune 중 하나로만** 진행되어 두 프로토콜 간 일관성은 확인되지 않았다.

요약하면, **공유 backbone + 공유 split + 동일 metric**으로 4가지 SSL objective $\times$ 2가지 평가 프로토콜 $\times$ 4가지 라벨 양 $\times$ feature 융합 변형을 한 데이터셋에서 비교한 작업은 — 우리가 아는 한 — 없다. 이 결핍이 본 연구의 자리매김이다.

2.2 일반 tabular SSL과의 관계

일반 tabular 데이터에 대한 SSL은 신용에 직접 적용되지 않더라도 방법론적 영감을 제공한다. VIME는 mask + value imputation 구조를, SCARF는 contrastive learning을 tabular에 적용한 대표적 작업이다. SAINT는 row-attention + intersample attention을 결합해 tabular에서 contextual 표현을 학습한다. 그러나 이들 작업의 공통된 한계는 (a) 짧은 row-wise context(시퀀스 없음), (b) GBM과 fair 조건에서 같은 hand-crafted feature 위에서 비교한 사례 부족이라는 점에 있다. 신용 시퀀스는 동일 고객의 시간축이 명시되어 있다는 점에서 순수 tabular와 다르며, 시퀀스 길이 13개월 $\times$ wide column(190개)이라는 독특한 형상은 NLP의 long-sequence 가정도, Vision의 dense-grid 가정도 직접적 으로 따라가지 않는다.

2.3 SSL 평가 프로토콜 관련 문헌

SSL 평가에서 linear probe와 full fine-tune이 다른 결과를 낼 수 있다는 관찰 자체는 NLP/Vision에서 이미 잘 알려져 있다. 일반적인 관행은 두 결과를 모두 보고하고, 둘 사이 차이를 representation의 분리 가능성과 transfer 학습 가능성을 함께 보여주는 지표로 해석하는 것이다. 그러나 tabular/credit SSL 문헌은 — 우리가 조사한 범위에서 — 두 프로토콜을 동시에 보고하는 경우가 드물고, 보고하더라도 (1) 같은 backbone에서, (2) 동일 split에서, (3) 정량 비교 표로 일관성 있게 정리한 작업은 거의 없다.

2.4 GBM-SSL 융합 (feature engineering으로서의 SSL)

심층 모델의 hidden state를 GBM의 추가 feature로 사용하는 아이디어는 새롭지 않다. Kaggle 산업에서는 “neural net OOF prediction을 GBM에 stacking하는” 방식이 표준 ensemble 트릭이며, 자동 차량 보험 risk와 fraud detection에서도 deep representation을 GBM 입력으로 합치는 시도가 보고되어 왔다. 그러나 이들은 주로 “더 좋은 성능”이라는 결과만 보고할 뿐, **deep feature가 hand-crafted feature의 무엇을 보완하는지, 어떤 customer segment에서 효과가 나는지, 얼마나 많은 deep feature를 더해야 marginal return이 음으로 돌아서는지 같은 분해 분석을** — 우리가 아는 한 — 신용 시퀀스 도메인에서 통제된 실험으로 수행한 작업은 없다.

3 데이터와 실험 설정

데이터셋. 본 연구는 American Express Default Prediction Kaggle Challenge 2022의 공개 데이터를 사용한다. 데이터는 458,913명의 고객에 대해 최대 13개월의 statement-level 거래 기록을 anonymized 형태로 포함한다. 각 statement는 약 188개의 numerical 및 11개의 categorical anonymized feature와 한 개의 statement 날짜(S_2)로 구성된다. Label은 customer-level이며, 마지막 statement 이후 18개월 내 default 여부의 이진 indicator로 정의된다. Class imbalance는 약 26%이며, 일부 고객은 13개월보다 짧은 history를 갖는다(cold start).

Customer-level 80/10/10 split. 모든 실험은 동일한 customer-level 80/10/10 stratified split을 사용한다. Split은 StratifiedShuffleSplit으로 target에 stratify 되어 두 패스(90/10 $\rightarrow$ 80/10 within 90%)로 생성되며, seed = 42로 고정되어 data/splits/v1.parquet에 결정론적으로 저장된다. 추가로 StratifiedKFold로 train+val 90% 안에서 5-fold CV index가 함께 저장된다. SHA-256 hash가 두 번 연속 실행에서 일치함을 확인했다.

평가 메트릭. 평가 메트릭은 Kaggle AMEX competition 공식 metric $M = 0.5 \cdot (G + D)$ 이다. 여기서 G 는 negative class에 weight 20을 부여한 normalized weighted Gini coefficient, D 는 cumulative weight 기준 top 4%에서 포착된 default rate이다. NumPy fast path와 pandas reference 구현을 9개 unit test로 10^{-9} 이내 일치를 검증했다. AMEX metric 외에 AUC, KS, log-loss도 모든 실험에서 함께 보고한다.

LightGBM Baseline. Baseline은 1,291개의 customer-level hand-crafted feature를 입력으로 하는 LightGBM 5-fold CV이다. 1st place 공개 hyperparameter (`learning_rate=0.01`, `num_leaves=100`, `min_child_samples=2400`, `reg_alpha=reg_lambda=0.5`, `colsample_bytree=0.4`, `subsample=0.8` with `freq 5`, `n_estimators=10500`, `early_stop=200`)을 그대로 사용. AMEX metric을 custom feval로 등록해 early stopping이 실제 task metric에 대해 작동하도록 한다. 이 baseline은 OOF AMEX 0.79222, test bagged AMEX 0.79558을 기록한다.

컴퓨팅 환경. 모든 실험은 단일 RTX 4070 Laptop GPU(8 GB VRAM, sm_89) + AMD Ryzen 9 7940HS(16 logical cores) + 32 GB RAM의 한 노트북에서 수행되었다. PyTorch 2.6.0+cu124, PyTorch Lightning 2.6.4, bfloat16 mixed precision을 사용한다. 클라우드 GPU는 한 번도 사용하지 않았다. 총 5단계 실험을 모두 합한 wall-time은 약 20–22 시간(compute hours)이다.

4 방법

4.1 공유 transformer encoder

본 연구의 모든 SSL objective는 동일한 transformer encoder backbone을 공유한다. 이 일관성은 “어느 objective가 좋은가”라는 질문이 architecture 교란 변수로 오염되지 않게 보장한다.

Feature embedder. Numerical 입력($F_{\text{num}} = 177$)은 train split에서 미리 계산된 mean/std로 z-score 정규화한 뒤, 결측은 0으로 채우고 별도의 0/1 결측 마스크와 함께 concat한다. 따라서 numerical branch의 입력 차원은 $2F_{\text{num}}$ 이며, 하나의 linear layer로 $d_{\text{model}} = 128$ 차원으로 사영된다. Categorical branch($F_{\text{cat}} = 11$)는 각 컬럼별 작은 embedding table(padding_idx=0의 MISSING 토큰 포함)을 거쳐 $d_{\text{cat}} = 8$ 차원 embedding을 얻은 뒤, linear layer로 d_{model} 에 사영한다. 최종 timestep embedding은 두 branch의 sum이며, 형상은 $(B, T, D) = (B, 13, 128)$ 이다.

Positional encoding과 CLS 토큰. Sequence length가 짧으므로($T \leq 13$) 학습형 positional embedding을 사용한다. masked, contrastive, hybrid는 sequence 맨 앞에 학습형 CLS 토큰을 prepend해 $(B, T + 1, D)$ 로 인코딩되며, 이 CLS 위치가 sequence-level summary 표현이 된다. next-step prediction은 인과적 구조의 명확성을 위해 CLS 없이 사용한다.

Transformer 본체. 4-layer Pre-LN transformer encoder. 각 layer는 8-head multi-head attention(head dim = 32), feed-forward dim = 512, dropout 0.1, GELU activation을 사용한다. Encoder의 parameter 수는 852,544개이며, SSL objective 모듈 전체는 약 869K–915K parameter 범위에 있다.

4.2 네 가지 SSL objective

Masked Feature Modeling (MFM). BERT-style masking을 table 형상에 맞게 적용. 매 batch에서 (timestep, feature) cell의 15%를 random sampling해 numerical은 0으로 zero-out (결측 mask를

True로 표시), categorical은 MISSING 토큰으로 대체한 후, encoder는 corrupted sequence를 받아 masked 위치의 원본 값/코드를 복원한다. Loss는 numerical MSE + categorical CE.

Next-Step Prediction (NSP). GPT-style autoregressive. 인과적 attention mask가 적용된 encoder가 position t 까지의 정보로 position $t + 1$ 의 feature 벡터를 예측한다.

Contrastive (SimCLR-style). 각 customer에 대해 두 가지 augmented view를 생성한다: (a) temporal cropping(균등 random sub-window, $L \geq 6$), (b) feature dropout (random 15%의 numerical 컬럼을 zero-out, categorical은 MISSING). 두 view 각각을 encoder + 2-layer projection head로 통과시켜 L_2 -normalized 128차원 embedding을 얻고, InfoNCE loss(temperature $\tau = 0.1$)를 계산한다.

Hybrid (Masked + Contrastive). 위 두 objective를 동일 batch에서 동시에 수행한다. Total loss는 $\alpha \cdot L_{\text{MFM}} + \beta \cdot L_{\text{contrastive}}$ 이며, $\alpha = \beta = 1$ 로 단순 가중합을 사용한다.

4.3 평가 프로토콜

같은 사전학습된 encoder를 세 가지 downstream 프로토콜로 평가한다.

(P1) Linear probe. Encoder를 freeze하고 customer-level mean-pool 표현(CLS도 포함)을 scikit-learn LogisticRegression로 5-fold customer-level CV에 맞추어 학습. 이 프로토콜은 "raw representation의 quality"를 측정.

(P2) Full fine-tune. Encoder + 작은 classification head(2-layer MLP + dropout)을 binary cross-entropy로 end-to-end 학습. AdamW(encoder lr = 10^{-4} , head lr = 10^{-3}), max_epochs = 8, patience = 3.

(P3) GBM-fusion (본 연구의 핵심 기여). 사전학습된 encoder를 freeze하고 모든 customer의 mean-pooled 128차원 embedding을 추출해, hand-crafted feature와 customer_ID로 join한 augmented feature table($1,291 + 128 = 1,419$ 컬럼)을 만든다. 이 augmented feature 위에서 Section 3의 LightGBM hyperparameter를 그대로 적용한 5-fold CV를 학습한다.

4.4 Multi-seed 통계적 신뢰도

Hybrid objective의 SSL pretrain을 seed $\in \{42, 1, 2\}$ 세 가지 random initialization으로 반복 수행하고, 각 seed에서 P3 결과를 측정한다. 보고하는 모든 GBM-fusion 숫자는 세 seed의 mean $\pm$ std (또는 명시되면 best single seed)이다. SSL pretrain seed 이외의 모든 요소는 결정론적이다.

표 1: 전체 phase 통합 결과 (test bagged AMEX, $n = 45,892$).

방식	Test AMEX	Δ vs Phase-1
Phase 5-D — 3 seeds 평균 (LightGBM + 128 SSL hybrid emb)	0.79700 $\pm$ 0.0006	+0.00142
Phase 5-D — Best single seed (seed = 1)	0.79768	+0.00210
Phase 4 — LightGBM + 128 SSL hybrid emb (seed 42)	0.79662	+0.00104
Phase 1 — LightGBM, 1,291 hand features (baseline)	0.79558	0
Phase 5-C — LightGBM + 4×128 SSL emb (1,803 feats)	0.79516	−0.00042
Phase 5-A (iii) — (hand − top-100) + SSL	0.79290	−0.00268
Phase 3 — Hybrid SSL + full fine-tune	0.79267	−0.00291
Phase 5-A (ii) — hand − top-100 (no SSL)	0.78966	−0.00592
Phase 2 — Next-step + linear probe (best probe)	0.73713	−0.05845
Phase 5-A (iv) — SSL alone (128 cols)	0.72916	−0.06642

5 결과

5.1 직접 경쟁: SSL 단독은 GBM을 못 이긴다

4가지 SSL objective를 각각 linear probe와 full fine-tune 두 가지 프로토콜로 평가한 결과, 어떤 조합도 Phase 1 LightGBM (test AMEX 0.79558)을 능가하지 못했다. Full fine-tune 기준으로 최고 결과는 Hybrid objective가 0.79267 (−0.00291), 가장 약한 결과는 Masked가 0.78996 (−0.00562)이었다.

5.2 프로토콜 격차: linear probe와 full fine-tune이 0.058 차이

같은 사전학습된 encoder를 두 프로토콜로 평가했을 때 차이는 일관되게 크다.

- Hybrid: 0.72629 $\rightarrow$ 0.79267 (+0.06638)
- Next-step: 0.73713 $\rightarrow$ 0.79142 (+0.05429)
- Masked: 0.72965 $\rightarrow$ 0.78996 (+0.06031)
- Contrastive: 0.71691 $\rightarrow$ 0.79107 (+0.07416)

특기할 만한 inversion은 Hybrid objective가 linear probe에서 4위(0.72629)였다가 full fine-tune에서 1위(0.79267)로 바뀌었다는 점이다. Contrastive 신호는 frozen 표현에서는 mean-pool feature에 직접 나타나지 않고 sequence-level invariance로만 존재하므로, classification head가 학습되어야 비로소 활용 가능한 정보 형태다. 즉 tabular SSL paper는 두 프로토콜의 결과를 반드시 함께 보고해야 한다는 것이 본 연구의 정량적 메시지다.




그림 1: 라벨 효율 곡선. GBM(파랑)이 모든 fraction에서 SSL(오렌지)을 상회한다. 격차는 fraction이 줄수록 커진다.

5.3 Few-shot 영역: GBM이 모든 라벨 fraction에서 우세

train+val 라벨 풀에서 stratified 1%, 5%, 25%, 100% subset을 sampling해 GBM과 SSL fine-tune(hybrid encoder)을 각각 학습하고 동일한 test에서 평가했다.

fraction	GBM test AMEX	SSL test AMEX	Δ (SSL - GBM)
1%	0.75891	0.70701	-0.0519
5%	0.77819	0.73968	-0.0385
25%	0.79140	0.77875	-0.0127
100%	0.79558	0.79267	-0.0029

GBM이 모든 fraction에서 우세하며, 격차는 라벨이 줄수록 증가한다. 이는 SSL의 “label-efficient encoder” framing이 신용 도메인 + 단일 GPU 규모에서는 지원되지 않음을 의미한다.

5.4 Feature 융합: GBM + SSL > GBM (+0.00142 ± 0.0006)

SSL 인코더의 mean-pooled 128차원 embedding을 customer_ID로 hand-crafted feature parquet와 join하여 augmented feature table(1,419 컬럼)을 만들고, Section 3의 동일한 LightGBM hyperparameter로 5-fold CV를 학습했다.

설정	OOF AMEX	Test bagged	Δ
Phase 1 — hand only (1,291)	0.79222	0.79558	—
Phase 4 — hand + 128 SSL (seed 42)	0.79278	0.79662	+0.00104
Phase 5-D — 3 seeds 평균	0.79271 ± 0.00018	0.79700 ± 0.0006	+0.00142 ± 0.0006




그림 2: Phase 5-D 통계적 robustness. 3 SSL pretrain seed(오렌지) 모두 Phase-1 GBM-only baseline(회색 dashed) 위. Mean $\pm$ std(파랑 errorbar).

표 2: Top-100 hand feature ablation.

#	Feature set	n_{cols}	Test AMEX
(i)	full hand (Phase 1)	1,291	0.79558
(ii)	hand – top-100	1,191	0.78966
(iii)	(hand – top-100) + SSL	1,319	0.79290
(iv)	SSL only	128	0.72916
(v)	full hand + SSL (Phase 4)	1,419	0.79662

3-seed mean test AMEX는 0.79700 ± 0.0006 이며, baseline 대비 $+0.00142$ 의 lift를 준다. t -statistic = $+0.00142 / (0.00060 / \sqrt{3}) \approx 4.1$ ($df = 2$). 표본 크기가 작아 정확한 p -value 는 ~ 0.05 – 0.07 수준이지만, 3/3 trial이 양의 방향이라는 정성적 사실이 더 결정적이다.

Feature importance 분석(LightGBM gain 기준 fold-0 학습)은 SSL embedding 이 GBM에 의해 무시되지 않음을 보인다: 1,419개 feature 중 SSL emb이 total gain의 2.45%, total split count의 9.79% 를 차지한다. Split %와 Gain %의 비대칭(10% vs 2.5%)은 GBM이 SSL embedding을 자주 사용하지만 결정적이지는 않은 split에 활용한다는 의미로, hand-crafted feature가 모호한 곳에서 tie-breaker로 기능함을 시사한다.

5.5 Ablation: SSL은 hand top-100의 55%를 자동 회복한다

Phase 1 baseline에서 LightGBM gain 기준 상위 100개 hand feature를 제거한 ablation을 수행했다. 네 가지 조합을 동일 hyperparameter, 동일 5-fold CV로 비교한다 (Table 2).

핵심 숫자는 (ii) $\rightarrow$ (iii)의 차이다. Top-100 hand feature 제거로 잃은 0.00592 중, SSL embed-




그림 3: Top-100 hand feature ablation 시각화. 상위 100 hand feature 제거 시 -0.00592 손실(빨강), SSL embedding을 다시 더하면 $+0.00324$ 회복(주황) — 회복률 $\approx 55\%$.




그림 4: Segment 분해. 세 가지 segment 축에서 per-segment AMEX (baseline = 파랑, augmented = 오렌지). **base-pred decile 0-3**에서 오렌지가 파랑보다 $+0.02 \sim +0.03$ 위에 있다.

ding을 다시 더하면 0.00324 가 회복된다 — 회복률 $\approx 54.7\%$. Hand-crafted feature engineering 의 가장 중요한 100개 컬럼이 담고 있던 신호의 절반 이상을 SSL이 unlabeled raw 시퀀스에서 자동 발견한 셈이다.

분해를 더 세밀하게 보면: full hand + SSL의 $+0.00104$ lift 중에서 추가 $+0.00220 (= 0.00324 - 0.00104)$ 는 hand feature와 redundant한 SSL의 부분이며, 남은 $+0.00104$ 는 hand feature가 잡지 못한 순수 orthogonal 신호이다.

5.6 Segment 분해: lift는 base-pred decile 0-3에 집중

$+0.00142$ 라는 평균 lift는 모든 customer에게 균등하게 분포되어 있을 필요가 없다. Base-pred decile로 customer를 10등분해 각 decile에서 AMEX 변화량(Phase 4 augmented – Phase 1 baseline)을 측정한 결과는 강하게 비균등하다.

Base-pred decile	Default rate	Δ AMEX
0 (GBM이 "안전"이라 함)	0.000	+ 0.0239
1	0.001	+ 0.0234
2	0.002	+ 0.0213
3	0.005	+ 0.0261
4	0.015	-0.0054
5-8	0.06 - 0.80	-0.001 ~ +0.007
9 (GBM이 "default"라 함)	0.964	+0.0029

Lift는 base-pred decile 0-3 — 즉 GBM이 “이 고객은 안전 하다”고 자신한 영역 — 에서 +0.02 ~ +0.03 수준으로 집중된다. 이 영역은 base rate가 0% ~ 0.5% 수준의 prime customer 그룹이며, 신용 risk 실무에서 가장 비싼 false-negative failure mode가 발생하는 위치다.

5.7 Multi-encoder negative scaling

NLP/Vision SSL의 직감 중 하나는 “더 많은 사전학습 신호를 stack 하면 성능이 증가한다”는 것이다. Hybrid encoder의 128차원 embedding 대신 4 encoder의 $4 \times 128 = 512$ 차원 embedding을 hand feature에 합쳐 1,803-feature GBM을 학습해 이 직감을 검증했다.

설정	OOF	Test bagged
Phase 4 — hand + 1 enc	0.79278	0.79662
Phase 5-C — hand + 4 enc	0.79314	0.79516

OOF는 개선되지만(+0.00036) test bagged는 악화된다(-0.00146). 이는 교과서적 overfitting 신호이며, 단일 encoder가 sweet spot임을 시사한다. NLP의 “more pretraining objectives = 더 좋은 표현” 직감 이 tabular credit + 단일 GPU 규모에서는 그대로 적용되지 않는다.

6 고찰

6.1 “Neural pretraining vs human pretraining” framing

Section 5.5의 가장 강한 정량 발견은 SSL embedding이 hand-crafted top-100 feature 신호의 55%를 자동 회복 한다는 사실이다. 이 숫자는 근본적인 framing을 제시한다.

신용 risk 실무에서 1,291개의 hand-crafted feature를 만드는 것은 단순한 전처리가 아니다. 어느 column이 “마지막 값”으로 의미를 갖는지, 어느 column이 “분산”으로 의미를 갖는지 결정하는 행위는 수십 년의 도메인 지식이 데이터 파이프라인에 인코딩된 implicit pretraining으로 볼 수 있다. 이 시각에서 우리의 baseline GBM은 “no pretraining” 모델이 아니라 “human pretrained” 모델이며, SSL은 그것과 경쟁할 수 있는 별도의 “neural pretrained” 표현을 제안하는 것이다.

이 framing 하에서 본 연구의 결과는 다음과 같이 재해석된다:

- 신용 raw 시퀀스 위에서 라벨 없이 10 epoch 학습된 869K parameter transformer가, **decades of expert engineering 이 만든 top-100 feature 중 55%를 자동으로 재발견했다.**
- 그러나 남은 45%는 SSL이 발견하지 못한다. 이는 expert feature engineering에 SSL이 접근할 수 없는 정보(예: 도메인-특정 ratio, business-meaningful date 구간, 결측 패턴의 정성적 해석)가 들어 있음을 의미한다.

NLP/Vision에서 raw text 또는 raw pixel은 거의 가공되지 않은 상태로 모델에 입력된다 — 그래서 SSL이 단순 표준화를 넘어서는 representation을 학습할 여지가 매우 크다. 반면 신용 데이터는 ETL pipeline에서 이미 정규화, dedup, anonymization, 기본 aggregation을 거친 후 모델에 입력된다. **Raw signal에 도메인 지식이 얼마나 사전 압축되어 있는가**가 SSL의 ceiling을 결정하는 가장 큰 변수일 가능성이 있으며, 이는 신용 SSL이 NLP SSL만큼 dramatic하게 작동하지 않는 이유의 후보 설명이다.

6.2 평가 프로토콜의 underspecification 문제

Section의 0.058 protocol gap은 단순한 quirk가 아니다. 같은 인코더에 대해 linear probe로 -0.058 을, full fine-tune으로 -0.003 을 보고하는 두 논문이 같은 데이터에 대해 정반대 인상을 줄 수 있다. 우리의 4 objective 비교에서 가장 극단적 사례는 Hybrid objective의 probe에서의 꼴찌 $\rightarrow$ fine-tune에서의 1위 inversion이다(objective ranking 이 평가 프로토콜로 완전히 뒤집힌다).

이 결과의 함의는 신용 SSL을 넘어서는 모든 **tabular SSL benchmark는 같은 인코더에 대해 두 프로토콜 결과를 모두 보고하는 것을 표준으로 삼아야 한다.** 그렇지 않으면 reader는 “SSL X가 SSL Y보다 좋다”라는 주장의 protocol-conditionality를 확인할 수 없다.

6.3 실무 도입 지침 (SSL as auxiliary feature engine)

신용 risk 실무자를 위한 구체적 지침:

1. **단일 SSL 모델로 GBM을 대체하지 말라.** 직접 경쟁에서 SSL이 일관되게 진다. 특히 라벨이 적을 때 SSL은 더 약하다.
2. **SSL을 추가 feature 엔진으로 다루라.** 단일 hybrid encoder 의 128차원 mean-pooled embedding을 기존 hand-crafted feature와 함께 GBM에 입력하면 평균 $+0.00142$ 의 lift를 robust하게 얻을 수 있다. 컴퓨팅 비용은 SSL pretrain 약 1시간 + embedding 추출 약 22분.
3. **Lift가 어디에 사는지 확인하라.** 평균 $+0.001$ 은 작아 보이지만 segment 분해는 lift가 base-pred decile 0-3에 $+0.02 \sim +0.03$ 수준으로 집중됨을 보였다. 신용 risk에서 가장 비싼 failure mode는 prime customer의 silent default이므로, **operational impact는 scalar metric이 시사하는 것보다 클 수 있다.**
4. **하나의 encoder로 충분하다.** Multi-encoder stacking은 추가 compute를 들고도 일반화에서 손실을 본다.

7 한계

본 연구의 결과는 다음 한계 안에서 해석되어야 한다.

- **(L1) 단일 데이터셋.** 모든 결과는 AMEX Default Prediction 2022 한 공개 dataset에서 측정되었다. Cross-dataset 검증은 본 연구의 범위를 벗어난다.
- **(L2) 작은 encoder.** 우리의 transformer encoder는 869K parameter로, NLP/Vision의 representative pretrained 모델 대비 1000배 이상 작다. 4M – 10M parameter encoder에서 결과가 어떻게 바뀔지는 직접 검증하지 않았다.
- **(L3) 단일 사전학습 budget.** 본 연구의 SSL pretrain은 $10 \text{ epoch} \times \text{batch size } 512 \times \text{limit_train_batches } 360$ ($\approx 50\%$ of one full pass)으로 제한되었다.
- **(L4) Segment 분석의 OOF 의존.** Section의 segment decomposition은 per-customer test prediction이 lgbm.py에서 dump되지 않아 trainval OOF 위에서 수행되었다.
- **(L5) Hybrid encoder만 융합에 사용.** Phase 4 + 5의 모든 융합 실험은 Hybrid encoder의 embedding에 한정되었다.
- **(L6) Seed 표본 3개.** t -statistic이 4.1로 강하긴 하나, $df = 2$ 이라는 작은 자유도에서 p -value는 0.05–0.07 경계에 머문다.
- **(L7) Cross-temporal split 부재.** 본 연구는 customer-level random 80/10/10 split을 사용한다. Out-of-time generalization은 측정되지 않는다.

이 한계들은 본 연구의 핵심 주장 — SSL을 GBM의 보조 feature 엔진으로 사용하면 통계적으로 의미 있는, segment-targeted lift를 얻는다 — 을 직접 위협하지는 않는다.

8 결론

본 연구는 신용 부도 예측에서 자기지도 사전학습(SSL)의 역할을 단일 데이터셋, 단일 GPU, 통제된 실험으로 분해했다. 세 가지 평가 축 — 프로토콜(linear probe vs full fine-tune), 라벨 양(1% – 100%), feature 융합(GBM 추가 feature로서의 SSL embedding) — 위에서 4가지 SSL objective를 동일 encoder backbone과 동일 customer-level split으로 비교했다.

핵심 발견 네 가지는 다음과 같다.

1. **SSL 단독은 GBM을 못 이긴다.** 어떤 objective $\times$ protocol 조합도 잘 튜닝된 LightGBM의 test AMEX 0.7956을 능가하지 못했다.
2. **평가 프로토콜이 결론을 0.058 뒤집는다.** 같은 인코더 에서 linear probe와 full fine-tune의 결과 차이가 -0.058 에서 -0.003 사이를 움직이므로, tabular SSL 평가는 두 프로토콜의 동시 보고를 표준으로 삼아야 한다.

3. **GBM + SSL은 GBM을 통계적으로 의미 있게 상회한다.** 3 seed mean test AMEX 0.79700 ± 0.0006 , baseline 대비 $+0.00142 \pm 0.0006$ ($t = 4.1$, 3/3 trial 양의 방향).
4. **이 lift는 false-negative tail에 집중된다.** Base-pred decile 0–3(GBM이 “안전”이라고 자신한 prime customer 영역) 에서 $+0.02 \sim +0.03$, 다른 decile에서는 거의 0. SSL embedding 은 hand-crafted feature top-100 신호의 약 55%를 unlabeled raw 시퀀스에서 자동 재발견하며, multi-encoder stacking은 음의 scaling을 보인다.

이 결과는 통합해서 다음 메시지를 준다. 신용 risk 도메인에서 SSL은 GBM의 경쟁자가 아닌 보조 feature 엔진이다. 그 가치는 GBM이 약한 영역 — 안전이라 잘못 분류된 prime customer의 silent default — 에 집중되며, 단일 encoder로 saturating한다. 도입 결정은 average scalar metric이 아닌 cohort-level loss로 평가되어야 한다.

후속 방향으로 cross-dataset 검증, 더 큰 encoder, segment-aware loss로의 fine-tune이 자연스럽다.

A 재현성 체크리스트

본 부록은 모든 실험을 재현하기 위한 정보를 한 곳에 모은다.

A.1 Code. 모든 코드는 <https://github.com/<TBD>/amex-ssl>에 공개되며, 다음 phase 브랜치로 구분된다: phase1-baseline, phase2-ssl, phase3-finetune, phase4-ensemble. 빌드는 `uv sync --extra dl` 한 줄, 환경 검증은 `uv run python scripts/check_env.py --phase 2` 한 줄로 충분하다.

A.2 Data. 모든 raw 데이터는 Kaggle American Express Default Prediction 2022 competition에서 공개되며, kaggle.json 인증 후 본 저장소의 `python -m amex.data.kaggle_download --mode full`로 다운로드 된다. 데이터 split은 결정론적 SHA-256 hash로 검증되며 (data/splits/v1.parquet, 13.6 MB), 모든 customer-level membership은 seed = 42로 고정된다.

A.3 Hyperparameter. 주요 hyperparameter는 Table 3에 정리.

A.4 Compute receipts. 모든 실험은 단일 RTX 4070 Laptop GPU(8 GB) + Ryzen 9 7940HS(16 logical cores) + 32 GB RAM의 노트북에서 수행. 총 wall-time:

- Phase 1 — LightGBM 5-fold (CPU): ~57 min
- Phase 2 — 4 SSL pretrain $\times$ 10 epochs (GPU): ~4 h
- Phase 3 — 4 full fine-tune (GPU): ~4 h
- Phase 4 — extract emb + augment + GBM: ~1.5 h

표 3: Hyperparameter 요약.

구성 요소	Parameter	값
Encoder	d_{model} / layers / heads	128 / 4 / 8
Encoder	FFN dim / dropout	512 / 0.1
Encoder	총 params	852,544
SSL train	optimizer	AdamW, $\beta = (0.9, 0.95)$
SSL train	lr / weight decay	3×10^{-4} cosine / 0.01
SSL train	epochs / batch / limit	10 / 512 / 360
SSL train	precision	bf16
Fine-tune	lr (encoder / head)	10^{-4} / 10^{-3}
Fine-tune	max epochs / patience	8 / 3
LightGBM	learning_rate / num_leaves	0.01 / 100
LightGBM	min_child_samples	2,400
LightGBM	reg_alpha / reg_lambda	0.5 / 0.5
LightGBM	colsample / subsample (freq)	0.4 / 0.8 (5)
LightGBM	n_estimators / early_stop	10,500 / 200

- Phase 5 (A+B+C+D) — ablation + segment + multi-enc + 3 seeds: ~ 11 h
- Total: $\sim 20 - 22$ GPU+CPU-hours

B Feature importance 전체 ranking

본문 Section 5.4의 fold-0 LightGBM feature-importance ranking은 저장소의 `reports/feature_importance_augme`에 저장되어 있다. 상위 25개 (gain 기준)와 SSL embedding 중 상위 10개는 본문에 이미 제시되었다. Section 5.5의 ablation을 위해 사용된 top-100 hand feature 목록은 `reports/feature_importance_hand_only.`의 `top_k_columns` 필드에 보존되어 있다.

C Split 결정론성

본 연구의 결과 비교 가능성은 모든 실험이 동일한 customer-level split 을 사용한다는 점에 의존한다. `data/splits/v1.parquet`는 `seed = 42`로 한 번 생성된 후 SHA-256 hash로 무결성 검증되어 git에 commit되었으며, 다음 의미를 갖는다 — `train` (367,129), `val` (45,892), `test` (45,892)의 customer-level membership과 `fold(0–4 within train+val, −1 for test)`가 모든 실험에서 동일하다.